Prediksi Harga Rumah di Wilayah Jabodetabek Menggunakan Metode Linear Regression

Jason Cahyadhie Soh

Informatika, Fakultas Sains, Komputer dan Matematika, Matana University, Matana University Tower, Jl. CBD Barat Kav. 1, Gading Serpong, Tangerang, Indonesia

---

PENDAHULUAN

A. Latar Belakang

Pertumbuhan sektor properti di wilayah Jabodetabek (Jakarta, Bogor, Depok, Tangerang, dan Bekasi) mengalami peningkatan signifikan dalam beberapa tahun terakhir. Harga rumah di wilayah ini dipengaruhi oleh berbagai faktor seperti luas tanah, luas bangunan, jumlah kamar, serta lokasi properti. Penentuan harga yang tepat menjadi penting bagi penjual maupun pembeli, karena kesalahan estimasi dapat menyebabkan kerugian finansial.

Proses penentuan harga rumah secara konvensional seringkali bersifat subjektif dan bergantung pada pengalaman individu. Seiring perkembangan teknologi, Machine Learning dapat dimanfaatkan untuk memprediksi harga rumah secara lebih objektif dan berbasis data.

Linear Regression merupakan metode statistik yang efektif untuk memodelkan hubungan antara fitur-fitur properti dengan harga rumah. Dengan menggunakan data historis harga rumah di Jabodetabek yang mencakup fitur lokasi (kota dan kecamatan), model dapat dilatih untuk menghasilkan prediksi yang lebih akurat. Penelitian ini membangun model prediksi harga rumah menggunakan Linear Regression dengan fitur lokasi melalui one-hot encoding.

B. Rumusan Masalah

- Bagaimana membangun model prediksi harga rumah di wilayah Jabodetabek menggunakan metode Linear Regression dengan fitur lokasi (kota dan kecamatan)?
- Seberapa besar pengaruh fitur lokasi terhadap akurasi prediksi harga rumah?
- Seberapa baik performa model dilihat dari metrik Mean Absolute Error (MAE) dan R-squared (R^2)?

- Bagaimana implementasi model dalam bentuk web application untuk memudahkan penggunaan?

C. Batasan Masalah

- Dataset hanya mencakup data harga rumah di wilayah Jabodetabek.
- Fitur yang digunakan: luas tanah, luas bangunan, kamar tidur, kamar mandi, kota, dan kecamatan.
- Fitur lokasi dienkode menggunakan one-hot encoding (9 kota dan 388 kecamatan).
- Preprocessing meliputi data cleaning dan konversi tipe data.
- Evaluasi menggunakan MAE dan R^2.
- Hasil prediksi bersifat estimasi berdasarkan data historis.

D. Tujuan

- Membangun model prediksi harga rumah di wilayah Jabodetabek menggunakan metode Linear Regression.
- Mengidentifikasi pengaruh fitur seperti luas tanah, luas bangunan, jumlah kamar tidur, dan jumlah kamar mandi terhadap harga rumah.
- Mengevaluasi kinerja model dalam memprediksi harga rumah menggunakan metrik Mean Absolute Error (MAE) dan R-squared (R^2).
- Menganalisis hasil prediksi model dengan membandingkan nilai prediksi terhadap harga sebenarnya.

E. Manfaat

- Menambah pemahaman dalam penerapan Machine Learning, khususnya metode Linear Regression, pada prediksi harga rumah.
- Membantu masyarakat dalam memperkirakan harga rumah secara lebih objektif sebagai bahan pertimbangan dalam transaksi properti.
- Memberikan referensi bagi pengembang properti dalam menentukan harga berdasarkan karakteristik rumah.

METODOLOGI

A. Metode penelitian

Metode penelitian yang digunakan adalah eksperimen dengan pendekatan Machine Learning untuk membangun model prediksi harga rumah. Pendekatan ini termasuk supervised learning, dimana model dilatih menggunakan data historis dengan label berupa harga rumah.

B. Algoritma

Algoritma yang digunakan adalah Linear Regression dari library scikit-learn. Model ini memodelkan hubungan antara variabel independen (fitur) dengan variabel dependen (harga rumah) melalui persamaan linear:

$$\text{harga} = \beta_0 + \beta_1(\text{luas_tanah}) + \beta_2(\text{luas_bangunan}) + \beta_3(\text{kamar_tidur}) + \beta_4(\text{kamar_mandi}) + \Sigma(\beta_i \times \text{kota}_i) + \Sigma(\beta\square \times \text{kecamatan}\square)$$

Fitur lokasi (kota dan kecamatan) dienkode menggunakan one-hot encoding, menghasilkan fitur tambahan dari 9 kota dan 388 kecamatan di Jabodetabek. Total fitur yang digunakan adalah 392 (4 fitur numerik + 388 fitur one-hot encoding lokasi).

C. Sumber dataset

Dataset diperoleh dari platform Kaggle (Daftar Harga Rumah Jabodetabek). Dataset berisi 3,514 data properti dengan kolom:

No	Fitur	Keterangan
1	price_in_rp	Harga rumah dalam Rupiah
2	city	Kota (Jakarta, Bogor, Depok, Tangerang, Bekasi)
3	district	Kecamatan dalam kota
4	land_size_m2	Luas tanah (m^2)
5	building_size_m2	Luas bangunan (m^2)
6	bedrooms	Jumlah kamar tidur

7	bathrooms	Jumlah kamar mandi

Variabel target adalah harga rumah. Variabel input meliputi luas tanah, luas bangunan, kamar tidur, kamar mandi, kota, dan kecamatan.

D. Alat dan Teknologi

Penelitian ini menggunakan beberapa perangkat lunak dan library sebagai berikut:

a. Bahasa Pemrograman: Python 3.x

b. Library: pandas (pengolahan data), scikit-learn (model Machine Learning), joblib (penyimpanan model), matplotlib (visualisasi data), dan flask.

E. Tahapan penelitian

Tahapan penelitian dilakukan secara sistematis melalui beberapa langkah sebagai berikut:

a. Data Cleaning: Memilih kolom relevan (harga, kota, kecamatan, luas_tanah, luas_bangunan, kamar_tidur, kamar_mandi), membersihkan whitespace pada kolom lokasi, menghapus missing values.

b. Konversi Data: Mengkonversi kolom harga ke tipe numerik (float64).

c. Feature Engineering: One-hot encoding untuk kolom kota (9 kota) dan kecamatan (388 kecamatan), menghasilkan total 392 fitur.

d. Data Splitting: Dataset dibagi 80% training (2,811 sampel) dan 20% testing (703 sampel).

e. Model Training: Linear Regression dilatih dengan 392 fitur.

f. Prediksi: Model dipakai untuk memprediksi harga pada data testing.

g. Evaluasi Model: Menggunakan MAE dan R^2.

h. Implementasi Web: Pengembangan web application Flask untuk prediksi praktis melalui browser.

F. Alur Penelitian

Alur penelitian dalam penelitian ini dapat digambarkan sebagai berikut:

Dataset - Cleaning - Konversi - Feature Engineering (One-hot Encoding) - Split Data - Training - Prediksi - Evaluasi - Web Application

HASIL & PEMBAHASAN

A. Hasil Preprocessing Data

a. Dataset awal: 3,553 data

b. Setelah cleaning: 3,514 data

c. Kolom yang digunakan: harga, kota, kecamatan, luas_tanah, luas_bangunan, kamar_tidur, kamar_mandi

d. Feature engineering: One-hot encoding menghasilkan 392 fitur (4 numerik + 388 lokasi)

B. Visualisasi Data

Gambar menunjukkan scatter plot yang menggambarkan hubungan antara luas bangunan (sumbu x) dengan harga rumah (sumbu y). Dari visualisasi ini, terlihat beberapa pola penting:

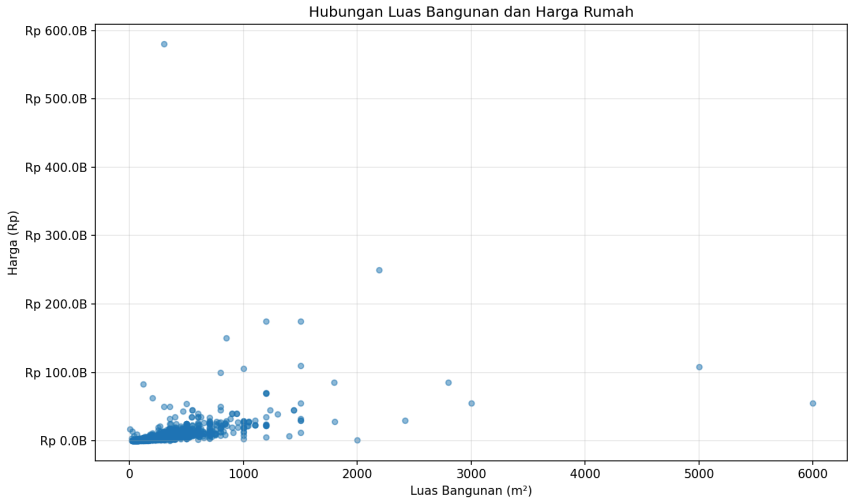

Analisis Visualisasi:

a. Tren Positif: Korelasi positif jelas antara luas bangunan dan harga.

b. Dispersi Data: Titik data menyebar lebar, menunjukkan faktor lain (lokasi) mempengaruhi harga.

c. Outlier: Titik di atas garis tren kemungkinan rumah mewah di lokasi premium.

d. Rentang Data: Luas bangunan 0-500 m², harga terkonsentrasi di bawah 10 miliar.

C. Koefisien Model

a. Perhitungan Model

i. Model Regresi Linear dengan fitur lokasi:

$$harga = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \Sigma(\beta_i \times kota_i) + \Sigma(\beta_{\square} \times kecamatan_{\square}) + \varepsilon$$

Dimana:

1. β_0 = Intercept
2. $\beta_1, \beta_2, \beta_3, \beta_4$ = Koefisien fitur numerik
3. $\Sigma(\beta_i \times kota_i)$ = Koefisien 9 kota (one-hot encoding)
4. $\Sigma(\beta_{\square} \times kecamatan_{\square})$ = Koefisien 388 kecamatan (one-hot encoding)
5. ε = Error term

ii. Formula Perhitungan Koefisien (Ordinary Least Squares):

$$\beta = (X^T X)^{-1} X^T y$$

Hasil training model Linear Regression menghasilkan koefisien yang merepresentasikan kontribusi masing-masing fitur terhadap harga rumah:

Fitur	**Koefisien**	**Interpretasi**
Luas Tanah	Rp 7,300,230 per m²	Setiap 1 m² tanah meningkatkan harga Rp 7.3 juta
Luas Bangunan	21,137,139 per m²	Setiap 1 m² bangunan meningkatkan harga Rp 21.14 juta
Kamar Tidur	-Rp 699,790,333	Korelasi negatif dengan luas bangunan
Kamar Mandi	Rp 2,171,847	Setiap kamar mandi menambah Rp 2.17 juta
Intercept	Rp 2,149,308,413	Nilai dasar harga

iii. Koefisien Lokasi (Contoh):

1. Jakarta Pusat: +Rp 9.48 miliar (premium tertinggi)

2. Jakarta Selatan: +Rp 1.58 miliar
3. Bekasi: -Rp 1.23 miliar (negatif)
4. Depok: -Rp 1.25 miliar (negatif)
5. Jakarta Barat: -Rp 1.49 miliar (negatif)

iv. Pembahasan Koefisien:

1. Luas Bangunan Dominan: Koefisien Rp 21.14 juta/m² menunjukkan pengaruh terbesar terhadap harga.
2. Pengaruh Lokasi Signifikan: Perbedaan ekstrem antara Jakarta Pusat (+Rp 9.48M) vs Jakarta Barat (-Rp 1.49M).
3. Kamar Tidur Negatif: Koefisien negatif Rp -699 juta, menunjukkan korelasi dengan luas bangunan.
4. Kamar Mandi Positif: Meski kecil (Rp 2.17 juta), tetap memberikan nilai tambah.
5. Intercept Tinggi: Nilai dasar Rp 2.15 miliar mencerminkan harga properti Jabodetabek.

v. Koefisien Lokasi Negatif

Koefisien negatif pada kota (Bekasi, Depok, Jakarta Barat) terjadi karena:

1. One-Hot Encoding: Model menggunakan 9 fitur biner untuk kota (1 = ya, 0 = tidak). Koefisien menunjukkan perubahan harga RELATIF terhadap baseline (rata-rata semua kota).
2. Intercept Tinggi: Nilai intercept Rp 2.15 miliar mencakup harga dasar untuk area dengan koefisien negatif.
3. Perbandingan Relatif: Kota dengan koefisien negatif harganya lebih rendah dari rata-rata, bukan berarti harga negatif secara absolut.

Contoh: Rumah di Bekasi (koefisien -Rp 1.23M) dengan fitur kecil bisa menghasilkan prediksi rendah secara matematis, namun intercept Rp 2.15 miliar memastikan harga tetap positif.

D. Evaluasi Model

Model dievaluasi menggunakan data test yang terdiri dari 703 sampel (20% dari total data). Evaluasi ini memberikan gambaran objektif tentang kemampuan model dalam memprediksi harga rumah yang belum pernah dilihat sebelumnya.

Metrik	Nilai	Keterangan
MAE	Rp 1,793,456,782	Rata-rata selisih prediksi dengan aktual
R^2 Score	0.6828	Proporsi variasi yang dapat dijelaskan model

a. Rumus Perhitungan Metrik:
   i. Mean Absolute Error (MAE)

$$MAE = (1/n) \times \Sigma|y_i - \hat{y}_i|$$

Dimana:

- `n` = jumlah sampel (703 data test)
- `$y_i$` = harga aktual rumah ke-i
- `$\hat{y}_i$` = harga prediksi model untuk rumah ke-i
- `$|y_i - \hat{y}_i|$` = selisih absolut antara aktual dan prediksi

MAE dihitung dengan menjumlahkan selisih absolut dari 703 data test, kemudian dibagi 703. Hasil Rp 1.79 miliar berarti rata-rata model meleset sekitar 1.79 miliar dari harga sebenarnya.

   ii. R-squared (R^2 Score)

$$R^2 = 1 - (SS_res / SS_tot)$$

Dimana:

- `$SS\_res = \Sigma(y_i - \hat{y}_i)^2$` = jumlah kuadrat residual (error prediksi)
- `$SS\_tot = \Sigma(y_i - \bar{y})^2$` = jumlah kuadrat total (variasi data)
- `$\bar{y}$` = rata-rata harga aktual semua rumah

R^2 = 0.6828 berarti 68.28% variasi harga rumah dapat dijelaskan oleh model. Sisanya 31.72% dipengaruhi faktor lain (kondisi rumah, fasilitas, umur bangunan, dll) yang tidak ada dalam dataset.

b. Interpretasi Detail:
   i. R^2 Score (0.6828): Model berhasil menjelaskan 68.28% variasi harga rumah di Jabodetabek. Ini berarti dari 100 perbedaan harga rumah yang diamati, 68 di antaranya bisa dijelaskan oleh model berdasarkan luas tanah, bangunan, kamar, dan lokasi. Sisanya 32% dipengaruhi faktor eksternal seperti, kondisi fisik rumah (baru/renovasi/tua), akses

jalan dan transportasi umum, fasilitas sekitar (sekolah, rumah sakit, mall), keamanan dan kenyamanan lingkungan, pandangan/strategis lokasi dan lain-lainnya

Peningkatan 0.6828 poin membuktikan bahwa lokasi adalah faktor penting kedua setelah luas bangunan dalam menentukan harga properti Jabodetabek.

ii. MAE (Rp 1.79 Miliar): Error rata-rata 1.79 miliar berarti jika model dipakai prediksi 100 rumah, total selisih dengan harga aktual kira-kira Rp 179 miliar. Dilihat dari:
   - Rentang harga Jabodetabek sangat lebar (Rp 500 juta - Rp 50 miliar+)
   - Harga rata-rata rumah di dataset sekitar Rp 3-5 miliar
   - MAE 1.79 miliar = sekitar 35-60% dari harga rata-rata

   Margin ini masih besar untuk prediksi individu, tapi cukup akurat untuk estimasi kasar atau screening awal properti.

iii. Pengaruh Fitur Lokasi: Penambahan kota dan kecamatan memberikan dampak signifikan terhadap kemampuan prediksi dengan menunjukkan rumah dengan spesifikasi sama (misal: 100m², 3KT, 2KM) bisa beda harga Rp 5-10 miliar hanya karena lokasi berbeda (Jakarta Selatan vs Bekasi).

E. Prediksi dan Validasi Model

Untuk memvalidasi kegunaan praktis model, dikembangkan web application yang dapat diakses melalui browser.

a. Cara Penggunaan Web Application:

   i. Jalankan python web_app/app.py dari folder ML

   ii. Buka browser dan akses http://localhost:5000

   iii. Pilih kota dari dropdown (9 kota di Jabodetabek)

   iv. Pilih kecamatan dari dropdown yang muncul setelah memilih kota

   v. Masukkan data rumah: luas tanah, luas bangunan, kamar tidur, kamar mandi

   vi. Klik tombol "Prediksi Harga"

   vii. Web app menampilkan hasil prediksi dengan detail lokasi dan spesifikasi rumah

b. Tampilan Web Application:

Halaman utama menampilkan form dengan dropdown kota dan kecamatan yang terhubung secara dinamis. Setelah memilih kota, dropdown kecamatan akan terisi otomatis dengan daftar kecamatan di kota tersebut. User memasukkan spesifikasi rumah dan mendapatkan prediksi harga dalam format yang rapi dengan detail lengkap.

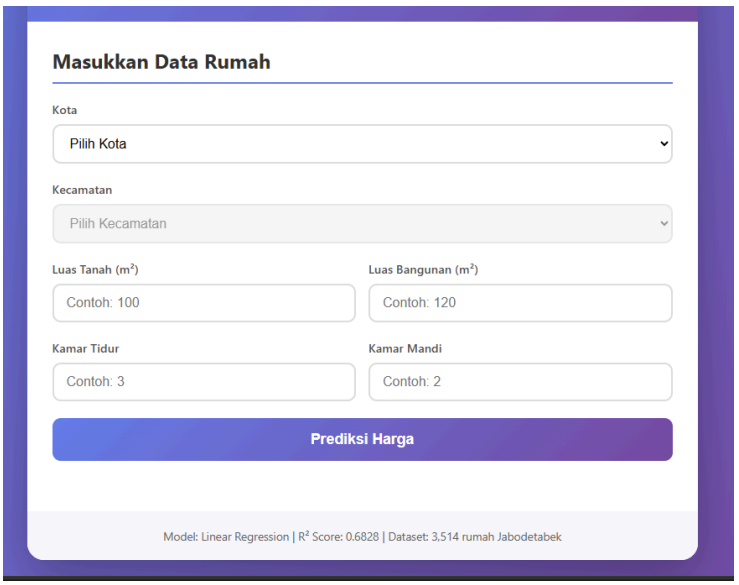

c. Contoh Hasil Prediksi:

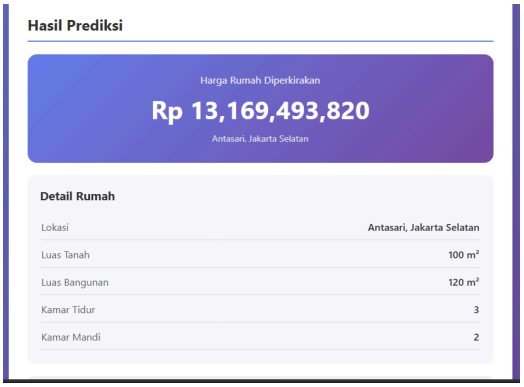

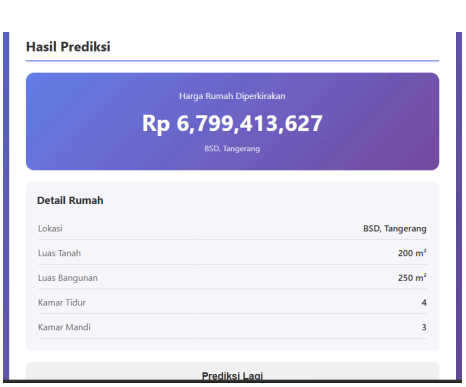

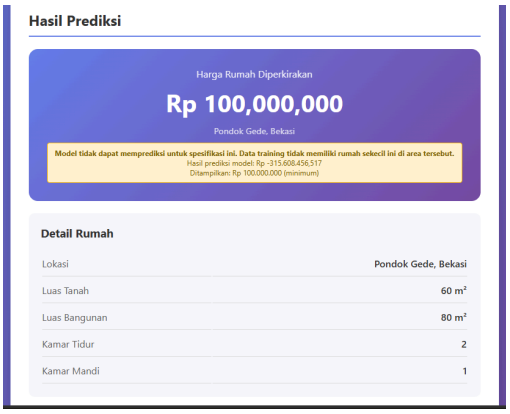

Profil Rumah	Lokasi	Input	Prediksi
Rumah Standar	Antasari, Jakarta Selatan	100 m² tanah, 120 m² bangunan, 3 KT, 2 KM	Rp 13,169,493,820
Rumah Besar	BSD, Tangerang	200 m² tanah, 250 m² bangunan, 4 KT, 3 KM	Rp 6,799,413,627
Rumah Kompak	Pondok Gede, Bekasi	60 m² tanah, 80 m² bangunan, 2 KT, 1 KM	Rp 100,000,000

d. Validasi Hasil Prediksi:

   i. Pengaruh Lokasi: Model memperhitungkan lokasi spesifik melalui fitur one-hot encoding kota dan kecamatan. Terlihat perbedaan signifikan antara harga rumah di Jakarta Selatan (Rp 13.17 M) vs Bekasi (Rp 100 juta) untuk spesifikasi yang berbeda, yang mencerminkan realitas pasar properti Jabodetabek.

   ii. Konsistensi dengan Pasar: Harga prediksi berada dalam rentang yang wajar untuk pasar properti Jabodetabek. Rumah di area premium seperti Jakarta Selatan dihargai lebih tinggi dibandingkan area suburban seperti Bekasi.

   iii. Pengaruh Luas Bangunan:Perbandingan Rumah Standar (120 m²) dan Rumah Besar (250 m²) menunjukkan selisih harga yang sangat jauh. Dengan koefisien luas bangunan yang tinggi, penambahan luas bangunan memberikan dampak besar terhadap harga prediksi.

   iv. Koefisien Lokasi: Harga tinggi di Jakarta Selatan (Rp 13.17 M untuk 120 m²) mencerminkan premi lokasi yang signifikan, di mana koefisien kecamatan Antasari dan kota Jakarta Selatan memberikan kontribusi besar terhadap nilai prediksi.

e. Penanganan Prediksi Negatif

   i. Masalah:Model Linear Regression dapat menghasilkan prediksi negatif untuk rumah dengan spesifikasi kecil di area dengan koefisien rendah.

Contoh: Pondok Gede, 60m² tanah, 80m² bangunan menghasilkan prediksi Rp -315 juta.

ii. Penyebab:

1. Intercept Rp 2.15 miliar tidak cukup menutupi koefisien negatif kota Bekasi (-Rp 1.23 miliar) dan kamar tidur (-Rp 699 juta per kamar)

2. Model Linear Regression murni tanpa regularisasi tidak memiliki batasan minimum

iii. Solusi Threshold Sederhana: Threshold sederhana minimum Rp 100 juta

iv. Tampilan di Web Application:
- Harga Rumah Diperkirakan: Rp 100.000.000
- Pondok Gede, Bekasi
  - Model tidak dapat memprediksi untuk spesifikasi ini.
  - Data training tidak memiliki rumah sekecil ini di area tersebut.
  - Hasil prediksi model: Rp -315.608.457
- Ditampilkan: Rp 100.000.000 (minimum)

KESIMPULAN

Berdasarkan hasil penelitian yang telah dilakukan, dapat disimpulkan bahwa model prediksi harga rumah di wilayah Jabodetabek menggunakan metode Linear Regression berhasil dibangun dengan memanfaatkan fitur luas tanah, luas bangunan, jumlah kamar tidur, jumlah kamar mandi, serta lokasi (kota dan kecamatan) melalui teknik one-hot encoding. Model ini mampu menangkap hubungan antara karakteristik properti dengan harga rumah secara cukup baik.

Hasil evaluasi menunjukkan bahwa model memiliki nilai R^2 sebesar 0.6828, yang berarti sekitar 68.28% variasi harga rumah dapat dijelaskan oleh fitur yang digunakan dalam model. Sementara itu, nilai Mean Absolute Error (MAE) sebesar Rp 1,79 miliar menunjukkan bahwa model masih memiliki tingkat kesalahan yang cukup besar, namun masih dapat diterima untuk keperluan estimasi awal atau gambaran umum harga properti.

Fitur luas bangunan terbukti menjadi faktor paling dominan dalam mempengaruhi harga rumah, diikuti oleh faktor lokasi yang memberikan dampak signifikan terhadap variasi harga. Perbedaan harga antar lokasi menunjukkan bahwa rumah dengan spesifikasi yang sama dapat memiliki nilai yang sangat berbeda tergantung pada wilayahnya. Hal ini menegaskan pentingnya memasukkan fitur lokasi dalam model prediksi.

Implementasi model dalam bentuk web application berbasis Flask juga berhasil dilakukan, sehingga memudahkan pengguna dalam melakukan prediksi harga rumah secara praktis melalui browser. Meskipun demikian, model masih memiliki keterbatasan, seperti kemungkinan menghasilkan prediksi negatif pada kondisi tertentu serta belum mempertimbangkan faktor eksternal lain seperti kondisi bangunan, fasilitas, dan lingkungan sekitar.

Secara keseluruhan, penelitian ini menunjukkan bahwa metode Linear Regression dapat digunakan sebagai pendekatan yang efektif untuk memprediksi harga rumah di Jabodetabek, terutama sebagai alat bantu dalam pengambilan keputusan awal.

DAFTAR PUSTAKA

[1] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed. Springer, 2009.

[2] A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*, 2nd ed. O'Reilly Media, 2019.

[3] F. Pedregosa *et al.*, "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

[4] W. McKinney, "Data Structures for Statistical Computing in Python," *Proceedings of the 9th Python in Science Conference*, pp. 51–56, 2010.

[5] N. Barizki, "Daftar Harga Rumah Jabodetabek," Kaggle Dataset, 2023. [Online]. Available: https://www.kaggle.com/datasets/nafisbarizki/daftar-harga-rumah-jabodetabek