Prediksi Harga Rumah di Wilayah Jabodetabek Menggunakan Metode Linear Regression

Jason Cahyadhie Soh

Informatika, Fakultas Sains, Komputer dan Matematika, Matana University, Matana University Tower, Jl. CBD Barat Kav. 1, Gading Serpong, Tangerang, Indonesia

---

PENDAHULUAN

A. Latar Belakang

Pertumbuhan sektor properti di wilayah Jabodetabek (Jakarta, Bogor, Depok, Tangerang, dan Bekasi) mengalami peningkatan yang signifikan dalam beberapa tahun terakhir. Harga rumah di wilayah ini dipengaruhi oleh berbagai faktor seperti luas tanah, luas bangunan, jumlah kamar, serta lokasi properti. Penentuan harga rumah yang tepat menjadi hal yang penting baik bagi penjual maupun pembeli, karena kesalahan dalam estimasi harga dapat menyebabkan kerugian finansial. Namun, proses penentuan harga rumah secara konvensional seringkali masih bersifat subjektif dan bergantung pada pengalaman individu.

Seiring dengan perkembangan teknologi, Machine Learning dapat dimanfaatkan untuk membantu memprediksi harga rumah secara lebih objektif dan berbasis data. Salah satu metode yang sederhana namun efektif adalah Linear Regression, yang mampu memodelkan hubungan antara fitur-fitur properti dengan harga rumah. Dengan menggunakan data historis harga rumah di Jabodetabek, model dapat dilatih untuk mengenali pola dan menghasilkan prediksi yang mendekati nilai sebenarnya. Oleh karena itu, penelitian ini dilakukan untuk membangun model prediksi harga rumah menggunakan metode Linear Regression guna memberikan estimasi harga yang lebih akurat dan sistematis.

B. Rumusan Masalah

- Bagaimana membangun model prediksi harga rumah di wilayah Jabodetabek menggunakan metode Linear Regression?
- Fitur apa saja yang berpengaruh terhadap harga rumah berdasarkan dataset yang digunakan?
- Seberapa baik performa model Linear Regression dalam memprediksi harga rumah dilihat dari nilai evaluasi seperti Mean Absolute Error (MAE) dan R-squared (R^2)?

- Bagaimana hasil prediksi harga rumah yang dihasilkan oleh model dibandingkan dengan harga sebenarnya?

C. Batasan Masalah

- Dataset yang digunakan terbatas pada data harga rumah di wilayah Jabodetabek yang diperoleh dari platform Kaggle.
- Fitur yang digunakan dalam penelitian ini hanya meliputi luas tanah, luas bangunan, jumlah kamar tidur, dan jumlah kamar mandi, tanpa mempertimbangkan faktor lain seperti lokasi detail, fasilitas, dan kondisi bangunan.
- Proses preprocessing data hanya mencakup pembersihan data (data cleaning) dan konversi tipe data, tanpa dilakukan teknik lanjutan seperti feature scaling atau feature engineering yang kompleks.
- Evaluasi model hanya menggunakan metrik Mean Absolute Error (MAE) dan R-squared (R^2).
- Hasil prediksi yang dihasilkan bersifat estimasi dan tidak mempertimbangkan kondisi pasar properti yang dinamis secara real-time.

D. Tujuan

- Membangun model prediksi harga rumah di wilayah Jabodetabek menggunakan metode Linear Regression.
- Mengidentifikasi pengaruh fitur seperti luas tanah, luas bangunan, jumlah kamar tidur, dan jumlah kamar mandi terhadap harga rumah.
- Mengevaluasi kinerja model dalam memprediksi harga rumah menggunakan metrik Mean Absolute Error (MAE) dan R-squared (R^2).
- Menganalisis hasil prediksi model dengan membandingkan nilai prediksi terhadap harga sebenarnya.

E. Manfaat

- Menambah pemahaman dalam penerapan Machine Learning, khususnya metode Linear Regression, pada prediksi harga rumah.
- Membantu masyarakat dalam memperkirakan harga rumah secara lebih objektif sebagai bahan pertimbangan dalam transaksi properti.
- Memberikan referensi bagi pengembang properti dalam menentukan harga berdasarkan karakteristik rumah.

METODOLOGI

A. Metode penelitian

Metode penelitian yang digunakan dalam penelitian ini adalah metode eksperimen dengan pendekatan Machine Learning untuk membangun dan menguji model prediksi harga rumah. Pendekatan yang digunakan termasuk dalam kategori supervised learning, dimana model dilatih menggunakan data historis yang memiliki label berupa harga rumah.

Algoritma yang digunakan dalam penelitian ini adalah Linear Regression, yang bertujuan untuk memodelkan hubungan antara variabel independen (fitur) seperti luas tanah, luas bangunan, jumlah kamar tidur, dan jumlah kamar mandi dengan variabel dependen yaitu harga rumah. Model ini bekerja dengan mencari hubungan linear terbaik antara variabel-variabel tersebut sehingga dapat digunakan untuk melakukan prediksi.

Proses penelitian dilakukan secara sistematis melalui beberapa tahapan, yaitu pengumpulan data, preprocessing data (data cleaning dan konversi data), pemilihan fitur, pembagian data menjadi data training dan testing, pelatihan model, prediksi, serta evaluasi model menggunakan metrik Mean Absolute Error (MAE) dan R-squared (R^2). Selain itu, dilakukan juga pengujian manual untuk melihat kemampuan model dalam memprediksi harga rumah berdasarkan input yang diberikan.

B. Sumber dataset

Dataset yang digunakan dalam penelitian ini diperoleh dari platform Kaggle dengan judul Daftar Harga Rumah Jabodetabek. Dataset ini berisi data properti di wilayah Jabodetabek yang terdiri dari 3.553 data.

Adapun fitur yang digunakan dalam penelitian ini adalah sebagai berikut:

No	Fitur	Keterangan
1	price_in_rp	Harga rumah dalam Rupiah
2	land_size_m2	Luas tanah (m^2)
3	building_size_m2	Luas bangunan (m^2)
4	bedrooms	Jumlah kamar tidur

5	bathrooms	Jumlah kamar mandi

Dalam penelitian ini, variabel target adalah harga rumah, sedangkan variabel input (fitur) meliputi luas tanah, luas bangunan, jumlah kamar tidur, dan jumlah kamar mandi.

C. Alat dan Teknologi

Penelitian ini menggunakan beberapa perangkat lunak dan library sebagai berikut:

a. Bahasa Pemrograman: Python 3.x

b. Library:

c. pandas (pengolahan data)

d. scikit-learn (model Machine Learning)

e. joblib (penyimpanan model)

f. matplotlib (visualisasi data)

D. Tahapan penelitian

Tahapan penelitian dilakukan secara sistematis melalui beberapa langkah sebagai berikut:

a. Data Cleaning

Pada tahap ini dilakukan pembersihan data dengan memilih kolom yang relevan dan menghapus data yang memiliki nilai kosong (missing value). Kolom yang digunakan adalah harga, luas tanah, luas bangunan, jumlah kamar tidur, dan jumlah kamar mandi.

b. Konversi Data

Data pada kolom harga dikonversi menjadi tipe numerik (float) agar dapat diproses oleh model Machine Learning.

c. Pemilihan Fitur (Feature Selection)

Fitur yang digunakan dalam model adalah:

i. luas_tanah

ii. luas_bangunan

iii. kamar_tidur

iv. kamar_mandi

Sedangkan variabel target adalah harga rumah.

d. Pembagian Data (Data Splitting)

Dataset dibagi menjadi dua bagian:

i. Data training sebesar 80%

ii. Data testing sebesar 20%

Pembagian ini bertujuan agar model dapat dilatih dan diuji menggunakan data yang berbeda.

e. Pembuatan dan Pelatihan Model

Model yang digunakan adalah Linear Regression dari library scikit-learn. Model dilatih menggunakan data training untuk menemukan hubungan antara fitur dan harga rumah.

f. Prediksi

Model yang telah dilatih digunakan untuk memprediksi harga rumah pada data testing.

g. Evaluasi Model

Evaluasi model dilakukan menggunakan metrik:

i. Mean Absolute Error (MAE)

ii. R-squared (R^2)

Metrik ini digunakan untuk mengetahui tingkat akurasi model dalam memprediksi harga rumah.

h. Pengujian Manual

Model diuji dengan memasukkan data rumah secara manual untuk melihat hasil prediksi harga berdasarkan input yang diberikan.

E. Alur Penelitian

Alur penelitian dalam penelitian ini dapat digambarkan sebagai berikut:

Dataset - Cleaning - Konversi - Feature Selection - Split Data - Training - Prediksi - Evaluasi

HASIL & PEMBAHASAN

A. Hasil Preprocessing Data

a. Dataset awal: 3.553 data

b. Setelah cleaning: 3.514 data

c. Kolom yang digunakan: harga, luas_tanah, luas_bangunan, kamar_tidur, kamar_mandi

B. Visualisasi Data

Gambar menunjukkan scatter plot yang menggambarkan hubungan antara luas bangunan (sumbu x) dengan harga rumah (sumbu y). Dari visualisasi ini, terlihat beberapa pola penting:

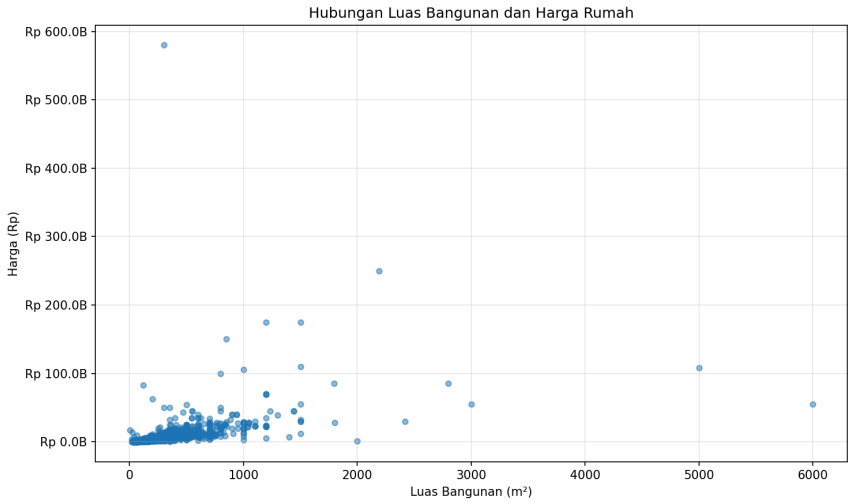

Analisis Visualisasi:

a. Tren Positif: Terdapat korelasi positif yang jelas antara luas bangunan dan harga. Semakin besar luas bangunan, harga cenderung meningkat. Hal ini sesuai dengan ekspektasi logis di pasar properti.

b. Dispersi Data: Titik-titik data menyebar cukup lebar, menunjukkan bahwa selain luas bangunan, terdapat faktor lain yang mempengaruhi harga (seperti lokasi, fasilitas, kondisi rumah).

c. Outlier: Beberapa titik berada jauh di atas garis tren, kemungkinan rumah mewah dengan fasilitas premium. Sebaliknya, titik di bawah tren mungkin rumah di lokasi kurang strategis.

d. Rentang Data: Luas bangunan berkisar 0-500 m² dengan harga terkonsentrasi di bawah 10 miliar rupiah.

C. Koefisien Model

a. Perhitungan Model

Model Regresi Linear menghitung hubungan antara fitur dan target dengan rumus:

1. Rumus Matematis:

$$harga = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \varepsilon$$

Dimana:

a. `$\beta_0$` = Intercept (nilai konstan)

b. `$\beta_1, \beta_2, \beta_3, \beta_4$` = Koefisien masing-masing fitur

c. `$X_1$` = Luas Tanah, `$X_2$` = Luas Bangunan, `$X_3$` = Kamar Tidur, `$X_4$` = Kamar Mandi

d. `$\varepsilon$` = Error term

2. Formula Perhitungan Koefisien (Ordinary Least Squares):

$$\beta = (X^T X)^{-1} X^T y$$

Hasil training model Linear Regression menghasilkan koefisien yang merepresentasikan kontribusi masing-masing fitur terhadap harga rumah:

Fitur	**Koefisien**	**Interpretasi**
Luas Tanah	Rp 5,235,380 per m²	Setiap tambahan 1 m² tanah meningkatkan harga sekitar Rp 5.2 juta
Luas Bangunan	Rp 25,567,700 per m²	Setiap tambahan 1 m² bangunan meningkatkan harga sekitar Rp 25.6 juta
Kamar Tidur	-Rp 739,623,901	Koefisien negatif, menunjukkan efek yang perlu dianalisis lebih lanjut
Kamar Mandi	Rp 143,515,905	Setiap tambahan 1 kamar mandi meningkatkan harga sekitar Rp 143.5 juta
Intercept	Rp 440,669,031	Nilai dasar harga ketika semua fitur bernilai nol

b. Pembahasan Koefisien:

   i. Luas Bangunan Dominan: Koefisien luas bangunan (Rp 25.6 juta/m²) jauh lebih besar daripada luas tanah (Rp 5.2 juta/m²). Ini menunjukkan bahwa luas bangunan memiliki pengaruh terbesar terhadap harga rumah. Hal ini masuk akal karena biaya konstruksi dan material untuk bangunan biasanya lebih signifikan daripada nilai tanah mentah.

   ii. Kamar Tidur Negatif: Koefisien negatif pada kamar tidur mungkin disebabkan oleh:

      1. Multikolinearitas dengan luas bangunan (rumah dengan lebih banyak kamar biasanya lebih besar)

      2. Rumah kecil dengan banyak kamar mungkin dianggap tidak efisien

      3. Perlu analisis lebih lanjut untuk memvalidasi hasil ini

   iii. Kamar Mandi Positif: Kamar mandi memiliki koefisien positif yang signifikan, menunjukkan fasilitas ini menjadi nilai tambah yang dihargai pembeli.

   iv. Intercept: Nilai intercept Rp 440 juta bisa diartikan sebagai nilai minimum atau "harga lahan dasar" meskipun dalam praktiknya rumah dengan fitur nol tidak realistis.

D. Evaluasi Model

Model dievaluasi menggunakan data test yang terdiri dari 703 sampel (20% dari total data). Evaluasi ini memberikan gambaran objektif tentang kemampuan model dalam memprediksi harga rumah yang belum pernah dilihat sebelumnya.

Metrik	**Nilai**	**Keterangan**
MAE	Rp 1,661,393,109	Rata-rata selisih prediksi dengan aktual
R^2 Score	0.5992	Proporsi variasi yang dapat dijelaskan model

Interpretasi Detail:

a. R^2 Score (0.5992): Nilai R^2 sebesar 0.5992 atau 59.92% menunjukkan bahwa model dapat menjelaskan hampir 60% variasi harga rumah dalam dataset. Dalam konteks prediksi harga properti yang dipengaruhi banyak faktor

kompleks (lokasi, kondisi pasar, fasilitas umum), nilai ini tergolong moderat hingga baik. Faktor lokasi yang tidak dimasukkan dalam model kemungkinan besar menjadi penyebab 40% variasi yang belum terjelaskan.

b. MAE (Rp 1.66 Miliar): Mean Absolute Error sebesar Rp 1.66 miliar berarti rata-rata prediksi model meleset sekitar 1.66 miliar rupiah dari harga aktual. Untuk rumah dengan harga rata-rata sekitar Rp 2-5 miliar di Jabodetabek, margin error ini masih dalam batas wajar meskipun idealnya lebih rendah.

c. Konteks Properti Jabodetabek: Dengan rentang harga rumah di Jabodetabek yang sangat luas (dari ratusan juta hingga puluhan miliar), MAE 1.66 miliar masih dapat diterima untuk prediksi kasar, namun perlu perbaikan untuk keputusan investasi yang lebih akurat.

E. Prediksi Manual dan Validasi Model

Untuk memvalidasi kegunaan praktis model, dilakukan prediksi manual menggunakan script `08_tes_manual.py`. Script ini menerima input interaktif dari user dengan fitur multi-input (dapat memasukkan beberapa rumah sekaligus) dan menampilkan hasil prediksi harga berdasarkan model yang telah dilatih.

a. Cara Penggunaan Script:

1. Jalankan `python 08_tes_manual.py`

2. Masukkan data rumah: luas tanah, luas bangunan, kamar tidur, kamar mandi

3. Pilih 'y' untuk menambahkan rumah lain, atau 'n' untuk melihat hasil

4. Script menampilkan prediksi harga untuk semua rumah yang diinput

```
Prediksi Harga Rumah - Multi Input
--------------------------------------

Masukkan data rumah:
Luas Tanah (m2): 100
Luas Bangunan (m2): 120
Jumlah Kamar Tidur: 3
Jumlah Kamar Mandi: 2
Ingin menambahkan rumah lain? (y/n): y

Masukkan data rumah:
Luas Tanah (m2): 200
Luas Bangunan (m2): 250
Jumlah Kamar Tidur: 4
Jumlah Kamar Mandi: 3
Ingin menambahkan rumah lain? (y/n): y

Masukkan data rumah:
Luas Tanah (m2): 60
Luas Bangunan (m2): 80
Jumlah Kamar Tidur: 2
Jumlah Kamar Mandi: 1
Ingin menambahkan rumah lain? (y/n): n
```

```
Hasil Prediksi:
--------------------------------------
Rumah 1:
  Luas Tanah: 100.0 m2
  Luas Bangunan: 120.0 m2
  Kamar Tidur: 3
  Kamar Mandi: 2
  Harga Prediksi: Rp 2,100,491,170
--------------------------------------
Rumah 2:
  Luas Tanah: 200.0 m2
  Luas Bangunan: 250.0 m2
  Kamar Tidur: 4
  Kamar Mandi: 3
  Harga Prediksi: Rp 5,351,722,206
--------------------------------------
Rumah 3:
  Luas Tanah: 60.0 m2
  Luas Bangunan: 80.0 m2
  Kamar Tidur: 2
  Kamar Mandi: 1
  Harga Prediksi: Rp 1,464,475,953
--------------------------------------
```

Profil Rumah	Input	Prediksi	Analisis
Rumah Standar	100 m² tanah, 120 m² bangunan, 3 KT, 2 KM	Rp 2,100,491,170	Harga sesuai untuk rumah menengah di pinggiran Jakarta
Rumah Besar	200 m² tanah, 250 m² bangunan, 4 KT, 3 KM	Rp 5,351,722,206	Harga premium, cocok untuk kawasan elit
Rumah Kompak	60 m² tanah, 80 m² bangunan, 2 KT, 1 KM	Rp 1,464,475,953	Harga terjangkau untuk rumah starter

b. Validasi Hasil Prediksi:

i. Konsistensi dengan Pasar: Harga prediksi untuk ketiga profil berada dalam rentang yang wajar untuk pasar properti Jabodetabek saat ini. Rumah dengan luas bangunan 120 m² dihargai sekitar Rp 2.1 miliar, yang masuk akal untuk lokasi suburban.

ii. Pengaruh Luas Bangunan: Perbandingan Rumah Standar (120 m² bangunan) dan Rumah Besar (250 m² bangunan) menunjukkan selisih harga Rp 3.25 miliar. Sesuai koefisien luas bangunan Rp 25.6 juta/m², perbedaan 130 m² seharusnya menambah Rp 3.32 miliar, yang konsisten dengan hasil prediksi.

iii. Limitasi Model: Model tidak memperhitungkan lokasi spesifik (Jakarta pusat vs Bekasi), sehingga prediksi mungkin kurang akurat untuk rumah di lokasi premium atau terpencil. Ini menjelaskan mengapa metrik evaluasi menunjukkan margin error yang cukup besar.

KESIMPULAN

Berdasarkan penelitian mengenai prediksi harga rumah di wilayah Jabodetabek menggunakan metode Linear Regression, dapat disimpulkan bahwa model yang dibangun berhasil memprediksi harga rumah dengan menggunakan fitur luas tanah, luas bangunan, jumlah kamar tidur, dan jumlah kamar mandi. Hasil koefisien menunjukkan bahwa luas bangunan memiliki pengaruh paling signifikan terhadap harga rumah, diikuti oleh kamar mandi dan luas tanah, sedangkan koefisien negatif pada kamar tidur mengindikasikan perlunya analisis lebih lanjut terhadap multikolinearitas atau interaksi antarfitur. Evaluasi model menggunakan R^2 sebesar 0,5992 menunjukkan bahwa model mampu menjelaskan sekitar 59,92% variasi harga rumah, sedangkan MAE sebesar Rp 1,66 miliar menunjukkan rata-rata selisih prediksi dengan harga aktual, yang tergolong moderat untuk pasar properti Jabodetabek. Prediksi manual yang dilakukan juga konsisten dengan harga pasar, sehingga model dapat dijadikan referensi estimasi awal dalam menentukan harga rumah. Meski demikian, model memiliki keterbatasan karena tidak memperhitungkan lokasi spesifik, kondisi bangunan, fasilitas tambahan, dan faktor pasar real-time, sehingga akurasi prediksi dapat meningkat dengan penambahan fitur dan data yang lebih lengkap.

DAFTAR PUSTAKA

[1] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed. Springer, 2009.

[2] A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*, 2nd ed. O'Reilly Media, 2019.

[3] F. Pedregosa *et al.*, "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

[4] W. McKinney, "Data Structures for Statistical Computing in Python," *Proceedings of the 9th Python in Science Conference*, pp. 51–56, 2010.

[5] N. Barizki, "Daftar Harga Rumah Jabodetabek," Kaggle Dataset, 2023. [Online]. Available: https://www.kaggle.com/datasets/nafisbarizki/daftar-harga-rumah-jabodetabek